

PROJETO DE PESQUISA (TCC) – VERSÃO FINAL INTEGRADA

Título

Raio de Atuação e Impacto Socioeconômico da UTFPR-CM frente aos Polos de TI do Paraná: uma Análise em Teoria dos Grafos

1. Problema de Pesquisa e Questões Norteadoras

A interiorização do ensino superior público no Paraná visou descentralizar o desenvolvimento tecnológico. No entanto, apesar de a UTFPR Campus Campo Mourão ter iniciado suas atividades no curso de Tecnologia em Sistemas para Internet (CSTI) em 2009, o efetivo impacto na região só pôde ser mensurado a partir da primeira turma de concluintes, em 2015.

Passados mais de 10 anos desde essa primeira formatura, há uma escassez de ferramentas de software que quantifiquem e visualizem, de forma integrada e científica, o real raio geográfico de captação de alunos e a aderência socioeconômica desses egressos frente ao mercado de trabalho formal da região. As bases de dados do governo (INEP e CAGED) existem de forma isolada, com assimetrias temporais e volumetria massiva, o que impede gestores acadêmicos de obter respostas precisas.

Para orientar o desenvolvimento computacional e a análise dos resultados, o trabalho será guiado pelas seguintes questões de pesquisa:

- QP1: Qual é o raio geométrico médio de atuação (atração de talentos) da UTFPR-CM na área de TI e como ele evoluiu ano a ano desde 2015?
 - QP2: Considerando uma modelagem em grafos, quais municípios atuam como os maiores "influenciadores locais" na exportação de estudantes de TI para o nosso campus e para os grandes polos do estado?
 - QP3: Como o mercado de trabalho formal de TI em Campo Mourão respondeu à oferta de profissionais ao longo da última década em termos de saldo de vagas e salários reais (corrigidos pela inflação via IPCA) se comparado aos grandes polos do Paraná?
-

2. Motivação

A união da Engenharia de Dados com a Teoria dos Grafos oferece um arcabouço computacional perfeito para resolver problemas de fluxo migratório e dinâmica demográfica. O projeto motiva-se tecnicamente pelo desafio de construir uma arquitetura de dados otimizada para processar séries temporais (2015–2025), calcular métricas de redes

complexas sobre coordenadas geográficas e disponibilizar essas informações em um dashboard web de alta performance. Institucionalmente, a pesquisa entrega uma ferramenta analítica inédita para a UTFPR-CM, permitindo visualizar sua evolução e comparar sua capilaridade com os grandes centros formadores do estado.

3. Objetivos

Objetivo Geral

Desenvolver um dashboard analítico web, munido de uma pipeline de engenharia de dados e modelagem em grafos, para mapear, visualizar e responder às três questões de pesquisa formuladas, comparando o impacto socioeconômico e o raio de atuação da UTFPR-CM em relação aos principais polos formadores de TI do estado do Paraná, considerando o recorte temporal de 2015 a 2025.

Objetivos Específicos

1. Estruturar uma pipeline de extração, transformação e carga (ETL) em Python para minerar, limpar e unificar os microdados históricos do INEP e do CAGED, limitando o escopo ao Paraná, à área de TI e ao período 2015–2025.
 2. Definir e implementar um critério metodológico claro e multifatorial para classificar os "grandes polos" de TI do estado, servindo como grupo de controle para as comparações. Os polos serão definidos em nível municipal (agregando-se todas as IES de TI sediadas no município).
 3. Modelar o fluxo de atração de estudantes como um Grafo Direcionado e Ponderado em nível municipal, no qual cada vértice representa um município paranaense e as arestas representam o fluxo total de alunos oriundos do município de origem com destino àquele município (agregando-se todas as IES de TI sediadas no destino). Implementar o cálculo de distância geométrica (Haversine) e métricas de centralidade (In-Degree e Out-Degree) para identificar municípios influenciadores e medir a evolução do raio de atuação (respondendo QP1 e QP2).
 4. Implementar uma rotina de correção monetária (deflacionamento) automática na série temporal de salários do CAGED utilizando o IPCA/IBGE, tratando as quebras metodológicas entre a RAIS e o Novo CAGED (insumo essencial para a QP3).
 5. Projetar e implementar o dashboard utilizando uma arquitetura que separe a persistência (PostgreSQL com visões materializadas) da camada visual interativa (Streamlit), realizando o deploy em infraestrutura de nuvem gratuita.
-

4. Método (Metodologia de Desenvolvimento)

O trabalho seguirá uma abordagem de pesquisa aplicada e desenvolvimento ágil, dividida em quatro fases macro:

- Fase 1: Coleta e Filtragem Semântica (ETL I): Download dos microdados brutos do INEP e CAGED. Scripts em Python (Pandas) para corte temporal (2015–2025), geográfico (Paraná) e de domínio (códigos Cine Brasil de cursos de TI e CBOs de

tecnologia). Atenção especial à compatibilização das séries do CAGED (pré e pós-e-Social).

- Fase 2: Definição dos Polos de Referência e Modelagem em Grafos (ETL II):
 - Agregação municipal (o conceito de "Polo"): Para evitar a comparação assimétrica entre uma instituição pequena (UTFPR-CM) e universidades centenárias (UFPR, UEM), os vértices do grafo representarão municípios, não IES individuais. O peso da aresta A
 - →
 - → B será a soma de todos os alunos que saíram do município A e foram estudar em qualquer instituição de TI localizada no município B. Isso permite comparar o ecossistema da UTFPR-CM (representando Campo Mourão) com o de Curitiba, Maringá e demais polos.
 - Justificativa Metodológica para a Agregação Assimétrica: A decisão de agregar todas as IES de TI nos municípios classificados como "grandes polos" (Curitiba, Maringá, Londrina, etc.) e, simultaneamente, isolar exclusivamente a UTFPR-CM no vértice de Campo Mourão decorre diretamente da natureza do objeto de pesquisa e das perguntas que orientam este trabalho.
 1. Unidades de análise distintas: Nos polos de controle, a unidade de análise é o município como ecossistema tecnológico. Para mensurar o porte e a atratividade desse polo, é imprescindível somar toda a produção de formandos de TI da cidade, independentemente da natureza jurídica (pública ou privada) da IES. A inclusão de instituições como a PUCPR (Curitiba) e a Unicesumar (Maringá) é essencial para capturar a massa crítica que define um "grande polo". Ignorá-las subestimaria o tamanho real do referencial comparativo.
 2. Isolamento do objeto central: Em Campo Mourão, a unidade de análise não é o "ecossistema da cidade", mas sim a instituição UTFPR-CM. Incluir a Faculdade Integrado (ou qualquer outra oferta privada local) no mesmo vértice contaminaria as métricas, pois o raio de atração calculado (QP1) e a centralidade no grafo (QP2) poderiam ser mascarados ou inflacionados pela oferta privada, impossibilitando a resposta à pergunta central: "Qual é o raio de atuação da UTFPR-CM?"
 3. Valorização da análise relativa: Ao agregar todos os concorrentes (públicos e privados) no vértice dos polos, a comparação torna-se, na verdade, mais desafiadora para a UTFPR-CM. O grafo contrasta uma única instituição pública do interior com a somatória de todas as IES das metrópoles. Se, mesmo assim, a UTFPR apresentar vantagens relativas (ex: alto CAGR do raio de atuação, alta retenção regional ou impacto per capita superior), a evidência de seu impacto territorial será ainda mais robusta e incontestável perante a banca.
 4. Transparência e limitação explícita: Esta assimetria é assumida e documentada como um recorte metodológico consciente. A pesquisa não tem a pretensão de medir o ecossistema total de Campo Mourão, mas sim a pegada geográfica e socioeconômica específica da UTFPR-CM. Trabalhos futuros poderão, legitimamente, expandir a agregação para incluir as instituições privadas locais, caso o objeto de estudo seja alterado para uma análise da "competição local" ou do "ecossistema completo" da região.

- Critério de seleção dos "grandes polos" (grupo de controle): Aplicação de um escore composto por: (a) total de concluintes de TI no município; (b) número de IES com cursos de TI no município; (c) estoque de empregos formais em TI no município (CAGED); (d) existência de programas de pós-graduação stricto sensu em Computação (CAPES). Selecionaremos os top-5 municípios como grandes polos para comparação detalhada.
- Modelagem com NetworkX: Construção do grafo direcionado e ponderado. Cálculo das métricas de centralidade de grau (In-Degree e Out-Degree) e do raio geométrico médio (distância de Haversine) para responder QP1 e QP2. Implementação do script de correção da inflação (IPCA) para responder QP3.
- Fase 3: Arquitetura de Armazenamento: Modelagem do banco PostgreSQL. Migração dos dados tratados e criação de indexação estratégica e visões materializadas para garantir respostas em milissegundos para a interface.
- Fase 4: Engenharia de Frontend e Deploy: Desenvolvimento da interface gráfica utilizando Streamlit, com mapas georreferenciados (Folium ou Plotly) e gráficos interativos que apresentem as respostas para as três QPs. Publicação em nuvem (Streamlit Cloud ou Render).

5. Hipóteses e Rastreabilidade de Dados

Embora em métricas absolutas (volume total de formandos, salários nominais) a UTFPR-CM não rivalize com os grandes centros metropolitanos, a análise orientada por grafos e indicadores relativos pode revelar que o campus supera os grandes polos em dimensões críticas para a avaliação institucional.

Para guiar a engenharia de dados do projeto, a tabela abaixo cruza cada hipótese com sua respectiva estratégia de medição computacional:

#	Hipótese	Como será medido (Algoritmo)	Fontes e Variáveis Críticas (Campos)
H1	Crescimento acelerado da capilaridade: A UTFPR-CM expandiu seu raio de atuação em ritmo superior ao dos polos consolidados.	Cálculo da distância de Haversine ano a ano e extração do CAGR (Taxa de Crescimento Anual Composto) da curva de linhas temporal.	INEP: CO_MUNICIPIO_NASCIMENTO, CO_MUNICIPIO_CURSO, NU_ANO_CENSO

H2	Alta retenção regional de talentos: A UTFPR-CM retém seus egressos na região em proporção maior do que os grandes polos retêm em suas áreas.	Cálculo da razão entre volume de concluintes e o saldo de contratações/vínculos ativos locais criados no mesmo município pós-formação.	INEP: CO_MUNICIPIO_CURSO CAGED: município (admissões e demissões)
H3	Valorização salarial real acelerada: Embora os salários nominais sejam menores, a taxa de crescimento real (deflacionada) supera a dos grandes polos.	Comparação do CAGR salarial da UTFPR-CM vs. média dos polos após aplicação do índice IPCA na série histórica para extrair o ganho real.	CAGED: salario, competencia, cbo (família TI) IBGE: Tabela histórica IPCA
H4	Impacto per capita desproporcional: A densidade de formandos de TI por habitante em Campo Mourão é superior à dos grandes polos.	Divisão do total de formandos do polo pela população residente estimada ($\times 100$ mil $\times 100$ mil habitantes) no ano correspondente.	INEP: QT_CONCLUINTE IBGE: Estimativas populacionais municipais
H5	Democratização do acesso no interior: A UTFPR-CM atrai proporcionalmente mais alunos oriundos de municípios que não possuem qualquer outra oferta pública de TI.	Cruzamento da cidade natal do egresso com a malha nacional de IES para verificar se havia outra vaga pública de TI ativa em seu município.	INEP: CO_MUNICIPIO_NASCIMENTO cruzado com cadastro de cursos ativos por município

H6	Eficiência na absorção pelo mercado local: O mercado formal de Campo Mourão gerou mais de uma vaga de TI por formando no período, indicando alta absorção.	Cálculo da razão de eficiência: $\frac{\text{Vagas Formais Criadas}}{\text{Total de Formandos}} \times \frac{\text{Total de Formandos}}{\text{Vagas Formais Criadas}}$ acumulada para Campo Mourão vs. a mesma razão nos grandes polos.	INEP: QT_CONCLUINTE CAGED: Saldo líquido (Admissões - Desligamentos)
----	---	--	---

6. Contexto e Fatores Exógenos

Para fornecer uma interpretação mais robusta dos resultados, o dashboard e a monografia incluirão marcadores temporais para três eventos exógenos:

Evento	Ano	Impacto potencial
Adoção do SISU pela UTFPR	2014	Ampliação do acesso nacional via ENEM. Nota metodológica: Como o SISU foi adotado em 2014, o reflexo geográfico nos concluintes do INEP começará a se manifestar de forma clara nas colações de grau a partir de 2017/2018.
Pandemia de COVID-19	2020	Isolamento social + digitalização forçada → aceleração do interesse por carreiras de tecnologia e potenciais saltos em raios de captação.
Popularização da IA Generativa (ChatGPT)	2022	Democratização do acesso à IA → aumento do interesse público por tecnologia e possível alteração no perfil/volume de ingressantes secundários.

7. Trabalhos Relacionados

O aluno deverá buscar e analisar na literatura três eixos de trabalhos:

1. Sistemas de Monitoramento de Egressos Acadêmicos: Trabalhos que utilizam questionários ou cruzamentos de dados nominais, contrapondo-os com a abordagem macro e pública (anônima) proposta aqui.
 2. Análise de Redes Complexas na Demografia/Migração: Artigos que aplicam Teoria dos Grafos (In-Degree, Out-Degree, Closeness) para mapear fluxos migratórios ou econômicos entre municípios.
 3. Ferramentas de BI Aplicadas à Gestão Pública/Universitária: Dissertações ou TCCs que criaram dashboards para visualização de microdados do governo, analisando gargalos de performance.
-

8. Sugestões de Bibliografia Válida

- Teoria dos Grafos e Redes: NEWMAN, Mark. Networks: An Introduction. Oxford, 2010. / BARABÁSI, Albert. Network Science. Cambridge, 2016.
- Engenharia de Dados: MCKINNEY, Wes. Python para Análise de Dados. Novatec, 2018. / SILBERSCHATZ et al. Sistema de Bancos de Dados. GEN LTC, 2020.
- Contexto Regional e Dados Públicos: IBGE. Divisão Regional do Brasil em Regiões Geográficas Imediatas e Intermediárias. Rio de Janeiro, 2017. / INEP. Microdados do Censo da Educação Superior – Manuais de Usuário (vários anos).